

对 NIPT 的时点选择与胎儿的异常判定的决策研究

摘要

产前检测是对母婴至关重要的环节，其可以及时发现胎儿异常，评估孕妇及胎儿的安危，保证母婴安全。而 NIPT 是一种通过采集母体血液、检测胎儿的游离 DNA 片段、分析胎儿染色体是否存在异常的产前检测技术。本文基于题目所给信息，本文对影响 NIPT 的关键指标与其他指标的关系进行分析，确定特定情况下的 NIPT 最佳时点，分析女婴是否异常的判定方法。

针对问题一，本文首先对 Y 染色体浓度、孕周数和孕妇 BMI 进行正态性检验，发现三者并不符合正态分布的规律。因此，采用 Spearman 相关分析法计算 Y 染色体浓度与孕周数和 BMI 的相关系数及其显著性，结果发现 Y 染色体浓度与两者呈现弱相关性。之后，本文采用非线性拟合方法建立 Y 染色体浓度与另外两者的模型关系，最后得到 R^2 较低，但显著性极高。

针对问题二，首先进行分析数据特征与数据清洗，用线性插值法或其他拟合方法计算每位孕妇的胎儿 Y 染色体浓度的最早达标周数，并通过计算每位孕妇多次检测的平均 BMI 来确定孕妇的唯一 BMI，在此基础上通过分位数分箱法将 BMI 分为 5 组。然后构造风险函数来量化风险数值，使用优化搜索算法在以每组总风险最小的目标下求得每组的 NIPT 最佳时点。在得出结果后，考虑到 Y 染色体浓度在检测时可能会有随机误差，因此本问引入 $\pm 0.5\%$ 的绝对误差，分析在此误差的影响下所求 NIPT 最佳时点和平均风险的变动情况，以此展现检测误差对结果的影响程度。

针对问题三，首先以原有的分组为一级分组，年龄、体重、身高等因素为二级分组子特征，用 K-means 优化组内一致性得到新的二级分组。然后应用每组数据训练逻辑回归模型，预测特定孕周下 Y 染色体浓度 $\geq 4\%$ 的概率，之后再根据题目中的条件进行风险分级，检测失败风险系数定为 1，错过治疗窗口期风险系数定为 10，定义风险函数。代入逻辑回归数值后通过不断优化得到最小风险对应的最佳时点，得出结果每组的最佳检测时间点应该在 12 周左右。最后，本文采用蒙特卡洛模拟法对误差的影响进行分析，得到时点标准差趋近于 0，说明结果具有相当强的抗干扰能力。

针对问题四，本题以染色体的非整倍体（存在为异常，不存在为正常）为目标变量，以其他数据为特征变量构建随机森林模型来进行求解。首先对特定变量进行独热编码，再对所有特征变量数据进行标准化处理，考虑到处理类别数量不平衡的问题，本题使用 SMOTE 过采样让模型更好地学习到少数类别的特征，从而提高模型的泛化能力和准确性。最终得到每一种类型的数据对异常判定的重要性得分和可以较为准确判断女胎是否正常的随机森林模型。

关键字： Spearman 相关系数 非线性回归分析 K-means 聚类 风险函数 随机森林

一、问题背景与重述

1.1 问题背景

无创产前检测技术（NIPT）是临床筛查胎儿染色体数目异常（如 21-三体综合征、性染色体异常）的重要手段，其检测准确性高度依赖母体血浆中胎儿游离 DNA 的浓度，对男胎而言，Y 染色体特异性序列的浓度更是决定结果可靠性的关键。尽早通过 NIPT 识别染色体异常胎儿，能为后续遗传咨询、产前诊断复核及妊娠决策争取时间，避免治疗窗口期缩短导致的母婴健康风险与临床处理难度增加。

临床实践证实，男胎 Y 染色体浓度并非恒定，而是与孕妇孕周数（随孕周推进，胎儿游离 DNA 浓度通常逐步升高）及身体质量指数（BMI）紧密相关——BMI 过高可能稀释母体血浆中的 Y 染色体序列，降低检测灵敏度。因此，依据 BMI 对孕妇进行科学分组（如按标准 BMI 区间分层），结合不同组别 Y 染色体浓度的孕周变化规律确定最佳检测时点，可在保障 NIPT 准确性的同时，最大限度提前异常发现时间，减少窗口期缩短的风险。

1.2 问题重述

为了研究各类孕妇群体合适的 NIPT 时点，附件给出了某地孕妇的数据。实际检测中，出现了测序失败，多次采血多次检测或一次采血多次检测的情况。依据给出的数据，建立模型，解决以下问题：

针对问题一，分析胎儿 Y 染色体浓度与孕周数和 BMI 等指标的相关特性，给出关系模型并检测显著性。

针对问题二，已知男胎孕妇的 BMI 是影响 Y 染色体浓度最早达标时间主要的因素，将孕妇 BMI 分组后给出区间和 NIPT 最适时点，使得孕妇风险最小。

针对问题三，题目要求综合考虑身高、体重和年龄对 Y 染色体浓度的影响，给出男胎孕妇的 BMI 分组和最佳 NIPT 时点，使得风险最小，并分析误差对结果的影响；

针对问题四，题目要求以女胎染色体非整倍体为判定结果，在考虑染色体的 Z 值、GC 含量、读段数及相关比例、BMI 等因素后，给出女胎异常的判定方法。

二、问题分析

针对问题一，首先对孕周数进行数据处理，统一换算成周数。接着检验 Y 染色体浓度、孕周数和 BMI 值是否符合正态分布的规律，根据检验结果，再来决定用 Pearson 相

关系数或 Spearman 相关系数进行分析。然后建立 Y 染色体浓度与孕周数和 BMI 之间的模型关系，最后检验模型的显著性。

针对问题二，本文将其分为三个步骤进行求解，首先根据孕妇的多次抽血检验结果，用合适的方法预测出胎儿 Y 染色体浓度达到 NIPT 所要求的 Y 染色体浓度的最小孕周，其次取每位孕妇多次检测结果的 BMI 平均值作为该孕妇的 BMI，并通过合理的方法对 BMI 进行分组，最后构造风险函数，通过优化搜索算法确定每一组的最佳 NIPT 时点，使得每组的平均风险最小，并且要增加误差项，分析误差对结果的影响。其中需要注意的是，Y 染色体浓度会受多种因素的影响，但为简化模型，本文在预测达标的最小孕周时仅考虑其与孕周的单独关系。

针对问题三，因其可看作是对问题二的进一步细化，要基于多种因素对 BMI 分组进行细化，然后确定每一组的最佳 NIPT 检测时间从而使得风险最小。因此本文在原有 BMI 分组的基础上考虑用 K-means 聚类的方法根据多种因素进行进一步的分组，对于这些分组通过逻辑回归模型来得到每组的 Y 染色体达标概率，然后代入风险函数通过优化算法得到最小值，输出每组的最佳 NIPT 检测时间。在探究检测误差对结果的影响时，采用蒙特卡洛模拟法，得到误差的影响。

针对问题四，因其为一个分类与判别类问题，因此本文考虑使用机器学习中的随机森林来求解此问题。经过对问题的详细分析，可以确定存在 21 号、18 号和 13 号染色体非整倍体的胎儿个体是异常个体，其余为正常个体。因此可以通过构造随机森林模型对胎儿进行分类，依据孕妇和胎儿的各项数据指标，判断胎儿是否存在以上三对染色体非整数倍情况，并给出各项数据对于判断的重要性程度。最后得出基于训练好的随机森林模型的判断方法。

三、模型假设

1. 假设在第二问中胎儿 Y 染色体浓度的最早达标时间只与孕周有关。
2. 假设错过治疗窗口期的风险系数远高于检测失败的风险系数。
3. 假设不同 IVF 妊娠方式对模型的建立无过大影响。
4. 女胎数据中每个胎儿无其他染色体异常情况，异常只会出现在 13 号，18 号，21 号染色体中。

四、符号说明

本文将文中使用的相关数据符号进行说明：

符号	说明	单位
i	孕妇编号	
j	抽血次数	次
k	检验次数	次
I	总孕妇数	
J	同一位孕妇抽血次数的最大值	次
K	同一次抽血检验次数的最大值	次
L	对应列数据中有效数据的总个数	
t_{ijk}	第 i 个孕妇第 j 次抽血并进行第 k 次检验时的孕周数	周
BMI_{ijk}	第 i 个孕妇第 j 次抽血并进行第 k 次检验时的 BMI	kg/m^2
m	组别	
n	每一组中孕妇的编号	
N_m	第 m 组中孕妇的数量	
C_1	检测风险失败系数	
C_2	治疗窗口期风险系数	
$risk_{mn}$	第 m 组中第 n 位孕妇的风险	
$RISK_m$	第 m 组中所有孕妇的风险和	
y	一位孕妇的 Y 染色体浓度	
p_{mn}	第 m 组的第 n 位孕妇在本组 NIPT 时点的 Y 染色体浓度	
W_m	第 m 组的 NIPT 时点	
w_{mn}	第 m 组第 n 位孕妇的最早达标时间	周
$g(t)$	一位孕妇对应计算 Y 染色体浓度的函数	
$R(t)$	子分组后的一个子组的风险函数	
$P(t)$	逻辑回归模型预测的“t 时刻 Y 染色体浓度 $\geq 4\%$ 的概率”	

五、数据处理

5.1 问题一

表中的检测孕周为 $rw+s$ 的形式，其中 r, s 均为一个正整数， r 表示周数， s 表示天数。为方便后续的模型求解与计算，本文统一将其化成周数，即

$$t_{ijk} = r_{ijk} + \frac{s_{ijk}}{7} \quad (1)$$

5.2 问题二

对于抽血次数小于等于 2 的孕妇，由于其 Y 染色体浓度多未达到 4%，其 NIPT 检测结果准确性难以得到保证，这为后续模型求解带来了较大的不便。因此，本文决定删除抽血次数小于等于 2 的孕妇的数据。

5.3 问题四

为适应随机森林模型道德输入要求，本文决定采用“众数填充缺失值 + 独热编码”将怀孕次数转换为数值型变量，采用“中位数填充缺失值 + 标准化”将其余 18 项数据进行去量纲化处理，并用 0 和 1 分别表示“染色体的非整倍体”的正常和异常情况。再采用分层抽样将数据按 7:3 划分为训练集和测试集，来检验模型的稳定性和正确性。

六、模型建立与求解

6.1 第一问求解

6.1.1 正态分布检验

本文决定用 Shapiro-Wilk、D'Agostino、Anderson-Darling、Kolmogorov-Smirnov 四种指标，来评判 Y 染色体浓度、孕周数和 BMI 是否符合正态分布。由于篇幅原因，这里仅展示 Y 染色体浓度的检测结果，如表1和图1所示。

检验方法	Shapiro-Wilk	D'Agostino	Anderson-Darling	Kolmogorov-Smirnov
统计量	0.9592	170.0120	7.2254	0.0524
p 值	0.0000	0.0000		0.0050
结果	非正态分布	非正态分布	非正态分布	非正态分布

表 1 Y 染色体浓度检验结果表

由于四个检测指标的结果均为非正态分布，故本文认为 Y 染色体浓度不符合正态分布。同时经过相似的检验过程后，本文认为孕周数和 BMI 也不符合正态分布。因此，本文决定不采用 Pearson 相关系数，而采用 Spearman 系数进行对其进行相关性分析 [1]。




图 1 Y 染色体浓度检验结果图

6.1.2 Spearman 相关系数

Spearman 相关系数被定义成等级变量之间的皮尔逊相关系数。对于样本容量为 n 的样本， n 个原始数据被转换成等级数据，相关系数 ρ 为

$$\rho = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

式中 $\bar{x}$ 与 $\bar{y}$ 均表示对应数据组的均值。

6.1.3 计算 Spearman 相关系数

根据处理后的数据，利用 python 软件分别计算 Y 染色体浓度与孕周数和 BMI 的 Spearman 相关系数 ρ 及 p 值，结果如表2所示：

分析项	Y 染色体浓度与孕周数	Y 染色体浓度与 BMI
相关系数 (ρ)	0.0843	-0.1550
p 值	0.0055	0.0000

表 2 Y 染色体浓度与孕周数和 BMI 的相关系数表

Y 染色体浓度与孕周数的相关系数为 0.0843，属于弱正相关。图2也表明随着孕周数增加，Y 染色体浓度会呈现出微弱的上升趋势。其 p 值为 0.0055，满足 $p < 0.05$ 的标准，显著性较强。这说明在统计学上有可靠的关联性，并非偶然的结果。




图2 Y 染色体浓度与孕周数和 BMI 的 Spearman 相关系数图

Y 染色体浓度与 BMI 的相关系数为-0.1550, 属于弱负相关。图2也表明随着 BMI 值增加, Y 染色体可能呈轻微的下降趋势。其 p 值为 0.0000, 远小于 0.05, 显著性极强, 说明可信度更高, 可明确排除“关联由偶然因素导致的可能性” [5]。

6.1.4 孕周数和 BMI 处理

在构建模型关系时, 为消除变量量纲不同带来的影响, 本文决定对孕周数和 BMI 值进行中心化处理, 即:

$$\begin{aligned} t'_{ijk} &= t_{ijk} - \overline{t_{ijk}} \\ BMI'_{ijk} &= BMI_{ijk} - \overline{BMI_{ijk}} \end{aligned} \quad (2)$$

式2中 $\overline{t_{ijk}}, \overline{BMI_{ijk}}$ 表示均值, 即

$$\begin{aligned} \overline{t_{ijk}} &= \frac{1}{L} \sum_{i=1}^I \sum_{j=1}^{J_i} \sum_{k=1}^{K_{ij}} t_{ijk} \\ \overline{BMI_{ijk}} &= \frac{1}{L} \sum_{i=1}^I \sum_{j=1}^{J_i} \sum_{k=1}^{K_{ij}} BMI_{ijk} \end{aligned}$$

6.1.5 模型的建立

由上述分析可知，胎儿 Y 染色体浓度与孕周数和 BMI 并非呈现出简单的线性关系，因此，本文决定用多元非线性函数进行拟合，设定模型形式为：

$$y = \beta_0 + \beta_1 t' + \beta_2 BMI' + \beta_3 t'^2 + \beta_4 BMI'^2 + \beta_5 t' BMI' \quad (3)$$

本文利用 python 软件用所给数据对函数进行拟合，首先计算出每组系数的 VIF(方差膨胀因子)，如表3。表3表明所有变量 VIF 小于 3，系数估计可靠。

变量系数	β_0	β_1	β_2	β_3	β_4	β_5
VIF	2.5646	1.4572	1.4670	1.1654	1.1998	1.1437

表 3 各系数 VIF 表

其次计算完整的模型结果，如表4所示。表中 * 越多，说明其显著性越强。

变量	系数 (β)	标准误	t 值	p 值	显著性
β_0	0.076241	0.001609	47.3926	0.000000	***
t'	0.000945	0.000306	3.0846	0.002091	**
t'^2	0.000132	0.000073	1.8013	0.071939	不显著
BMI	-0.001692	0.000378	-4.4759	0.000008	***
BMI'^2	-0.000161	0.000068	-2.3619	0.018362	*
$t' BMI$	0.000092	0.000088	1.0435	0.296958	不显著

表 4 回归变量分析结果

模型整体检验为： $F = 10.7778$ ， $p \approx 0 < 0.001$ ，说明模型整体较为显著。

模型解释力为： $R^2 = 0.0484$ ，调整后 $R^2 = 0.0439$ ，说明模型能解释 4.8% 的变异。从图中可以看出变量中 BMI 的系数较大，显著性在除了常量以外的变量中最高，说明其对 Y 染色体浓度的影响较强；相反的， t'^2 与 $t' BMI$ 的系数较小，相应的显著性也更低，说明其对 Y 染色体浓度影响较小，可以忽略不计。

6.2 第二问求解

6.2.1 模型的准备

为给出分组的区间和最佳 NIPT 的时点，在剔除掉总检测次数小于等于 2 的孕妇的数据后，本文将分两种情况来确定 Y 染色体浓度。

6.2.2 计算最早达标时间 w_{mn}

情况一：针对多次检验结果，胎儿 Y 染色体浓度存在低于 4% 的项、并且存在高于 4% 的项的孕妇，本文决定采用线性回归法来拟合胎儿 Y 染色体浓度与孕周数的关系，如公式4：

$$g_1(t) = y_0 + \frac{y_1 - y_0}{t_1 - t_0}(t - t_0) \quad (4)$$

其中 (t_0, y_0) 与 (t_1, y_1) 分别为紧邻 $y = 4\%$ 两侧的点。对于每一位孕妇，在公式4中，令 $g_1(t) = 4\%$ ，即可计算得到 w 值。

情况二：针对多次检验结果，胎儿 Y 染色体浓度检测结果都低于 4% 或者都高于 4% 的孕妇，经过线性拟合、保守估计法和样条插值法等多次尝试 [4]，本文最终决定采用如下对数函数来拟合胎儿 Y 染色体与孕周数的关系，如公式5：

$$g_2(t) = b + \ln t \quad (5)$$

式5中 b 值由孕妇的数据换元后经拟合得到。同样的，令 $g_2(t) = 4\%$ ，即可得到 w 值。

6.2.3 分组

本文将剩余的 251 位孕妇在不同时期检测的 BMI 取平均值后，利用分位数分箱法，将其分成五组，结果如表5所示：

组别	BMI 分组	孕妇数
1	$20.702 < \text{BMI} \leq 29.945$	51
2	$29.945 < \text{BMI} \leq 30.983$	50
3	$30.983 < \text{BMI} \leq 32.693$	50
4	$32.693 < \text{BMI} \leq 34.451$	50
5	$34.451 < \text{BMI} \leq 42.819$	50

表 5 BMI 分组情况表

6.2.4 模型建立与求解

本文根据医学常识，得到一个约束条件，如式6：

$$10 \leq W_m \leq 30 \quad (6)$$

又根据 p_{mn} 与 $g(t)_{mn}$ 的定义，本文得到了另一个约束条件，如式7：

$$p_{mn} = g(W_m)_{mn} \quad (7)$$

为实现风险值的减小，本文定义了对每个孕妇个体的风险函数，如公式8：

$$risk_{mn} = 100 \times \max\{p_{mn} - 0.04, 0\} + \max\{W_m - w_{mn}, 0\} \quad (8)$$

式8中， $\max\{a, b\}$ 表示 a, b 两者之间的较大值。

因此，根据以上约束条件和风险函数建立求解最低风险的模型为：

$$\min RISK_m = \sum_{n=1}^{N_m} risk_{mn} \quad (9)$$

$$\begin{cases} 10 \leq W_m \leq 30 \\ p_{mn} = g(W_m)_{mn} \end{cases}$$

模型中， $m = 1, 2, 3, 4, 5$.

利用 python 软件求解得到的结果如表6所示：

组别	BMI 分组	孕妇数	平均风险	最佳 NIPT 时点
1	20.702<BMI≤29.945	51	2.54952556	17.40911522
2	29.945<BMI≤30.983	50	2.899437029	16.84457286
3	30.983<BMI≤32.693	50	2.667796691	16.70413119
4	32.693<BMI≤34.451	50	3.540013227	17.05281213
5	34.451<BMI≤42.819	50	2.891072203	17.21827343

表 6 BMI 分组情况表

考虑到检测误差的存在，我们假设每位孕妇在检测胎儿 Y 染色体浓度时存在 0.5% 的绝对误差，图3展示了存在绝对误差时的重新求解结果。

由 Y 染色体浓度在检测时的 0.5% 的绝对误差对此问结果的影响可知，存在的小范




图3 误差对求解结果数据的影响

围误差对结果影响非常小，这说明此问的结果稳定性非常高。

6.3 第三问求解

6.3.1 模型准备

问题三承接问题二，在问题二说明了 BMI 是影响胎儿 Y 染色体浓度的最早达标时间的主要因素，要求直接根据 BMI 来进行合理分组；而问题三则要求综合考虑身高，体重，年龄，检测误差等因素来进行分组，整体框架仍然是对 BMI 进行划分，这表明在即使孕妇是相同的 BMI 条件下，其他指标的不同也会对胎儿 Y 染色体浓度达标时间造成不可忽视的影响。因此本文考虑在题目推荐的 BMI 区间（[20,28)，[28,32)，[32,36)，[36,40)，40 以上）下利用其他有效特征进行合理的二次分组，在二次分组中寻找最佳的 NIPT 检测时间，即动态分组策略。

6.3.2 分组方法及结果

在进行二次分组的时候，结合多种因素分析本文决定选择用 K-means 聚类分析算法，即基于相似性度量，将相近的样本归为同一个子集，使得相同子集中各元素间差异性最小，而不同子集间的元素差异性最大，从而进一步划分子组，实现“BMI + 多因素”的分层分组。利用 python 软件求解得到的子组划分结果如表7所示。

对其中每一个子组进行多因素分析，结果如表8。

子分组	孕妇数	组内达标比例	0 类样本数	1 类样本数
[20, 28)-子组 1	7	0.933	1	14
[20, 28)-子组 2	1	0.500	2	2
[28, 32)-子组 1	82	0.882	30	225
[28, 32)-子组 2	83	0.908	26	258
[32, 36)-子组 1	58	0.821	32	147
[32, 36)-子组 2	73	0.927	17	217
[36, 40)-子组 1	19	0.569	28	37
[36, 40)-子组 2	13	0.857	4	24
40+-子组 1	5	0.667	4	8
40+-子组 2	3	0.833	1	5

表 7 孕妇相关指标按 BMI 分组及子组

子分组	最小孕周	最大孕周	平均孕周	平均年龄 (岁)	平均体重 (kg)
[20, 28)-子组 1	12.143	25.286	17.962	29.867	70.019
[20, 28)-子组 2	13.143	23.143	17.964	31.000	53.000
[28, 32)-子组 1	11.000	27.714	17.086	28.424	82.848
[28, 32)-子组 2	11.000	26.429	16.156	29.176	74.168
[32, 36)-子组 1	11.143	24.714	16.362	29.469	92.833
[32, 36)-子组 2	11.286	29.000	16.661	28.876	82.698
[36, 40)-子组 1	11.857	26.429	18.831	29.354	102.879
[36, 40)-子组 2	11.286	26.000	19.408	26.071	92.694
40+-子组 1	12.857	24.286	19.060	28.583	111.008
40+-子组 2	12.000	23.857	19.500	32.333	123.167

表 8 多因素分析结果表

子组划分完成后，为了后续对风险函数的求解，我们建立了每组的逻辑回归模型 [3]，用来预测特定孕周数下 Y 染色体浓度大于等于百分之四的概率。这里展示出各子组逻辑回归模型性能（AUC 值），见表9。

表9中 AUC 值全部大于等于 0.65，说明模型预测效果良好，能较准确地根据“BMI + 年龄 + 体重 + 身高 + 孕周”多因素，预测某孕周下 Y 染色体浓度是否达标可以为后续风险函数的求解提供可信概率。

BMI 子组	AUC 值	样本数
[20, 28)-子组 1	1.000	15
[20, 28)-子组 2	样本量不足或标签单一，跳过训练	
[28, 32)-子组 1	0.690	255
[28, 32)-子组 2	0.669	284
[32, 36)-子组 1	0.741	179
[32, 36)-子组 2	0.777	234
[36, 40)-子组 1	0.677	65
[36, 40)-子组 2	0.875	28

表 9 各子组逻辑回归模型性能计

6.3.3 建立风险函数与模型求解

综合上述分析，本文决定建立以下风险函数来量化在对应组别中不同孕周数检测的风险值，见式10。

$$R(t) = C_1(1 - p(t)) + C_2t \quad (10)$$

为方便计算，本文决定取 $C_1 = 1$ ， $C_2 = 10$ ，函数前者乘积为检测失败风险，后者乘积为治疗窗口期风险。其中风险系数的设定是参考实际应用中两种风险的实际影响，错过治疗最佳时期的影响显然更大，这一系数设定与实际情况是符合的。

接下来通过不断地优化来找寻在不同子组中 $R(t)$ 的最小值，从而确定最优的 NIPT 检测时间点。这里根据题目条件，得到 $10 \leq t \leq 25$ 。采用有界区间最小化方法，结合上面训练好的逻辑回归模型（通过在不同子组中输入 t 得到对应的达标概率）后，得到了如下结果，见表10和图4。




图 4 各子组最佳 NIPT 时点图

子分组	最佳 NIPT 时点 (周)	最小风险值	时点达标概率	组内孕妇数
[20,28)-子组 1	12.14	122.401	0.028	7
[28,32)-子组 2	11.00	110.809	0.191	83
[28,32)-子组 1	11.00	110.019	0.981	82
[32,36)-子组 2	11.29	113.846	0.011	73
[32,36)-子组 1	11.14	111.434	0.995	58
[36,40)-子组 2	11.29	113.857	0.000	13
[36,40)-子组 1	11.86	118.845	0.727	19
40+-子组 1	12.86	128.601	0.970	5
40+-子组 2	12.00	120.115	0.885	3

表 10 各子组最佳 NIPT 时点表

6.3.4 误差分析和结论

题目中要求分析检测误差对结果的影响，本文采用蒙特卡洛模拟 [4][6] 来检测误差对检测时点的影响，对每个子组的原始 Y 染色体浓度，添加服从“均值 = 0、标准差 = 0.005”的正态分布误差，得到模拟后的 Y 浓度，再重新判定达标标签 ($\geq 4\%$ 为 1，否则为 0)。再设定 50 次模拟次数之后重新进行上述流程，得到新的最佳 NIPT 检测时点，与之前得到的数据进行对比得到如下结果，见表 11。

子分组	模拟平均时点 (周)	时点标准差	95% 置信区间 (周)
[20,28)-子组 1	12.14	0.0	[12.14, 12.14]
[28,32)-子组 2	11.00	0.0	[11.0, 11.0]
[28,32)-子组 1	11.00	0.0	[11.0, 11.0]
[32,36)-子组 2	11.29	0.0	[11.29, 11.29]
[32,36)-子组 1	11.14	0.0	[11.14, 11.14]
[36,40)-子组 2	11.29	0.0	[11.29, 11.29]
[36,40)-子组 1	11.86	0.0	[11.86, 11.86]
40+-子组 1	12.86	0.0	[12.86, 12.86]
40+-子组 2	12.00	0.0	[12.0, 12.0]

表 11 检测误差对时点的影响（蒙特卡洛模拟）表

通过求解结果和误差分析，可以看到为避免错过最佳治疗窗口期，孕妇整体最佳 NIPT 检测时间均落在 12 周左右，整体上来看 BMI 越大，最佳检测时间点越靠后，其

中 20 28 组中不满足这一规律，这可能是因为 BMI 落在这一区间内的孕妇数量过少（题目中说明了数据中大多为高 BMI 孕妇）导致得到的结果不具有一般性，实际最佳 NIPT 检测时间应该是在 11 周左右。同时 40 组的数据虽然孕妇数目较少，但也可以看出最佳 NIPT 检测时间点明显滞后，符合 BMI 与胎儿 Y 染色体浓度早期负相关的实际规律，也进一步验证了第一问的准确性。

同时，经过 50 次模拟运算得到的时点标准差无限趋近于 0，最佳 NIPT 时点也未发生任何波动，时点选择对检测误差具有绝对抗干扰能力，说明了结果在临床应用中具有较高的可靠性，即这些分组有其实际应用价值，检测误差对结果的影响很小。

6.4 第四问求解

6.4.1 模型构建

随机森林算法是由多棵决策树集成的分类模型，通过 Bootstrap 抽样构建多棵树，最终以投票方式确定预测结果。查阅文献 [2]，本文发现其优势在于：

- 1. 对高维特征不敏感，无需特征选择；
- 2. 抗过拟合能力强，泛化性能优异；
- 3. 可输出特征重要性，便于结果解释。

本文利用 python 的 sklearn 库实现模型，采用超参数调优方法，优化目标为宏平均 $F1$ 分数，并用 AUC 和特征重要性评估模型性能，具体参数网格如表12。

n_estimators	max_depth	min_samples_split	min_samples_leaf
100,200,300	0,10,15	2,5	1,2

表 12 参数网格表

表12中 n_estimators 表示决策树数量，max_depth 表示树最大深度，min_samples_split 表示分裂节点最小样本数，min_samples_leaf 表示叶节点最小样本数。

6.4.2 模型训练

使用训练集对随机森林模型进行训练，得到最佳模型。

6.4.3 模型结果与分析

经过网络搜索，得到的最佳参数如表13所示。

在测试集上，模型的表现为：

n_estimators	max_depth	min_samples_split	min_samples_leaf
200	10	2	1

表 13 最佳参数网格表

分类报告如表14所示。对于正常值 0 的精确率为 0.92，而异常值的精确率为 0.39，表明模型对正常值的预测能力较强，但预测异常值的能力略显不足。

样本	精确率	召回率	F1 分数	支持数
0	0.92	0.93	0.93	162
1	0.39	0.35	0.37	20
准确率			0.87	182
宏平均	0.65	0.64	0.65	182
加权平均	0.86	0.87	0.87	182

表 14 分类报告表

混淆矩阵热力图如图5所示，从图5也可以看出，模型对正常值的预测结果较好，但对异常的预测能力仍有待提高。




图 5 混淆矩阵热力图

各因素特征重要性得分如图6所示。图6表明，孕妇临床特征（如 BMI、体重、年龄、怀孕次数）和基因测序特征（如染色体 GC 含量、染色体 Z 值、X 染色体浓度）两类相

比，基因测序特征的整体重要性更突出，说明基因层面的分子数据对胎儿染色体非整倍体的预测贡献更大，这与医学常识相符 [3]。




图6 特征重要性得分图

其他可视化分析如图7所示。绘制 ROC 曲线,结果如图7a所示。AUC 值为:0.728395061728395, 这表明模型具有较强的区分能力。实际标签与预测概率对比图如图7b所示, 表明实际标签与预测概率一致性较好。异常概率分布如图7b所示, 其中位数为 0.65, 说明多数样本的预测置信程度较高。

七、模型评价

7.1 模型的优点

1. 通过线性插值法和其他拟合方法估计出每位孕妇的胎儿 Y 染色体浓度的最早达标时间，为量化风险数值提供了数据基础。
2. 通过 K-means 聚类分组得到的子分组一致性较高，在进行多因素分析的时候关联性更强。




图7 其他可视化分析图

3. 逻辑回归模型性能（AUC）全部大于 0.65，得到的 Y 染色体浓度达标概率具有可靠性。
4. 蒙特卡洛模拟得到的时点标准差趋近于 0，模型的抗误差干扰能力强。
5. 在解决类别数量不平衡的问题时，使用了 SMOTE 过采样让模型更好地学习到少数类别的特征，从而提高模型的泛化能力和准确性。
6. 在构建随机森林模型时定义了参数网格，让模型在拟合时可以选择出最好的一组参数。

7.2 模型的缺点

1. 通过线性插值法和其他拟合方法估计出的结果准确性不是很高，对风险评估有一定影响。
2. 部分组别孕妇数目过少，且高 BMI 孕妇数目占比大，得到的结果对于低 BMI 孕妇的适用能力较差，后续需要结合更多数据进行检验分析。
3. 训练集训练出的随机森林模型对预测集的判断能力不佳，尚有改进空间。

参考文献

- [1] De Winter J C F, Gosling S D, Potter J. Comparing the Pearson and Spearman correlation coefficients across distributions and sample sizes: A tutorial using simulations and empirical data[J]. Psychological methods, 2016, 21(3): 273.
- [2] Breiman L. Random forests[J]. Machine learning, 2001, 45(1): 5-32.
- [3] 豆包，字节跳动公司，2025-09-06
- [4] DeepSeek,DeepSeek-V3.1, 深度求索（DeepSeek），2025-09-06
- [5] 吴丽芳, 林小玲, 徐雪琴, 等. 不同孕周胎儿游离 DNA 含量变化及其影响因素 [C], 浙江省医学会检验医学分会, 浙江省医师协会检验医师分会.2016 年浙江省检验医学学术年会论文汇编. 温州市中心医院检验科温州医科大学定理临床医院产前诊断中心;;2016:226.
- [6] Metropolis, N., & Ulam, S. (1949). The Monte Carlo method. Journal of the American Statistical Association, 44(247), 335 - 341.

附录 A 孕周数和 BMI 正态性检验的图表

检验方法	Shapiro-Wilk	D'Agostino	Anderson-Darling	Kolmogorov-Smirnov
统计量	0.9177	170.5468	29.9579	0.1308
p 值	0.0000	0.0000		0.0000
结果	非正态分布	非正态分布	非正态分布	非正态分布

表 15 孕周数检验结果表

检验方法	Shapiro-Wilk	D'Agostino	Anderson-Darling	Kolmogorov-Smirnov
统计量	0.9429	175.4159	11.9033	0.0689
p 值	0.0000	0.0000		0.0001
结果	非正态分布	非正态分布	非正态分布	非正态分布

表 16 BMI 检验结果表




图 8 孕周数和 BMI 检验结果图

附录 B 问题一相关代码

```
import pandas as pd
import numpy as np
import statsmodels.api as sm
from statsmodels.stats.outliers_influence import variance_inflation_factor
import warnings
warnings.filterwarnings('ignore')
def preprocess_data(file_path):
    df = pd.read_excel(file_path, sheet_name="男胎检测数据")
```

```

df = df[["更改版孕周数", "孕妇BMI", "Y染色体浓度"]].dropna()
df = df[(df["更改版孕周数"] >= 10) & (df["更改版孕周数"] <= 25)]
df = df[(df["孕妇BMI"] >= 20) & (df["孕妇BMI"] <= 45)]
# 变量中心化
df["中心化孕周"] = df["更改版孕周数"] - df["更改版孕周数"].mean()
df["中心化BMI"] = df["孕妇BMI"] - df["孕妇BMI"].mean()
print(f"有效数据量: {len(df)} 条")
return df

def build_models(df):
Y = df["Y染色体浓度"]
X1, X2 = df["中心化孕周"], df["中心化BMI"]
# 主效应模型
X_main = pd.DataFrame({
    "常数项": 1, "中心化孕周": X1, "中心化孕周2": X1**2,
    "中心化BMI": X2, "中心化BMI2": X2**2
})
model_main = sm.OLS(Y, X_main).fit()
# 完整模型 (含交互项)
X_full = X_main.copy()
X_full["中心化孕周×BMI"] = X1 * X2
model_full = sm.OLS(Y, X_full).fit()
return model_main, model_full, X_main, X_full

def output_results(model_main, model_full, X_main, X_full):
print("=== 主效应模型结果 ===")
print(f"R2 = {model_main.rsquared:.4f}, 调整R2 = {model_main.rsquared_adj:.4f}")
print(f"F统计量 = {model_main.fvalue:.4f}, p值 = {model_main.f_pvalue:.6f}")
# VIF检查
vif_main = [variance_inflation_factor(X_main.values, i) for i in range(X_main.shape[1])]
print(f"VIF值: {[f'{v:.2f}' for v in vif_main]}")
print("\n系数结果:")
for var, coef, pval in zip(X_main.columns, model_main.params, model_main.pvalues):
sig = "***" if pval < 0.001 else "*" if pval < 0.01 else "" if pval < 0.05 else ""
print(f"{var}: {coef:.6f} (p={pval:.6f}) {sig}")
print("\n=== 完整模型结果 ===")
print(f"R2 = {model_full.rsquared:.4f}, 调整R2 = {model_full.rsquared_adj:.4f}")
print(f"F统计量 = {model_full.fvalue:.4f}, p值 = {model_full.f_pvalue:.6f}")
# VIF检查
vif_full = [variance_inflation_factor(X_full.values, i) for i in range(X_full.shape[1])]
print(f"VIF值: {[f'{v:.2f}' for v in vif_full]}")
print("\n系数结果:")
for var, coef, pval in zip(X_full.columns, model_full.params, model_full.pvalues):
sig = "***" if pval < 0.001 else "*" if pval < 0.01 else "" if pval < 0.05 else ""
print(f"{var}: {coef:.6f} (p={pval:.6f}) {sig}")
if __name__ == "__main__":
df = preprocess_data("附件 - 副本.xlsx")
model_main, model_full, X_main, X_full = build_models(df)
output_results(model_main, model_full, X_main, X_full)

```

附录 C 问题二相关代码

```
import pandas as pd
import numpy as np
from scipy.optimize import curve_fit
import warnings
warnings.filterwarnings("ignore")
def linear_interpolation(x_data, y_data):
    """线性插值找到Y=0.04对应的X值"""
    sorted_idx = np.argsort(x_data)
    x_sorted, y_sorted = x_data[sorted_idx], y_data[sorted_idx]
    for i in range(len(x_sorted) - 1):
        y1, y2 = y_sorted[i], y_sorted[i + 1]
        if (y1 < 0.04 <= y2) or (y1 >= 0.04 > y2):
            x1, x2 = x_sorted[i], x_sorted[i + 1]
            if x2 != x1: # 避免除零
                x_target = x1 + (0.04 - y1) * (x2 - x1) / (y2 - y1)
            if x_target >= 12 and not (np.isinf(x_target) or np.isnan(x_target)):
                k = (y2 - y1) / (x2 - x1)
                b = y1 - k * x1
                return x_target, f"Y = {k:.6f} * X + {b:.6f}", "线性插值"
    return None, None, None
def log_fitting(x_data, y_data):
    """对数拟合 Y = ln(X) + b"""
    try:
        def model(x, b):
            return np.log(x) + b
        popt, _ = curve_fit(model, x_data, y_data)
        b_fit = popt[0]
        if not (np.isinf(b_fit) or np.isnan(b_fit)):
            x_target = np.exp(0.04 - b_fit)
            if not (np.isinf(x_target) or np.isnan(x_target)):
                return x_target, f"Y = ln(X) + {b_fit:.6f}", "拟合"
    except:
        pass
    return None, None, None
def process_data(file_path):
    df = pd.read_excel(file_path, sheet_name="男胎检测数据")
    results = []
    for name, group in df.groupby('孕妇代码'):
        if len(group) <= 2:
            continue
        x_data = group['检测孕周'].values
```

```

y_data = group['Y染色体浓度'].values
avg_bmi = group['孕妇BMI'].mean()
# 优先尝试线性插值
x_target, func_str, method = None, None, None
if (y_data > 0.04).any() and (y_data < 0.04).any():
x_target, func_str, method = linear_interpolation(x_data, y_data)
# 如果插值失败, 使用拟合
if x_target is None:
x_target, func_str, method = log_fitting(x_data, y_data)
if x_target is not None:
results.append([name, x_target, method, avg_bmi, func_str])
result_df = pd.DataFrame(results, columns=['孕妇代码', '预测孕周', '方法', '平均BMI',
      '函数表达式'])
result_df.to_excel("预测结果_有效数据.xlsx", index=False)
print(f"共成功处理了 {len(result_df)} 位孕妇的数据")
return result_df
if __name__ == "__main__":
result_df = process_data("附件_转换后_末次月经补充.xlsx")

```

附录 D 问题三相关代码

```

import pandas as pd
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import roc_auc_score
import scipy.optimize as opt
# 读取数据
data = pd.read_excel("男胎检测数据.xlsx", usecols=["孕妇代码", "年龄", "体重", "更改版孕周数",
      "孕妇BMI", "Y染色体浓度", "身高"])
for c in ["年龄", "体重", "更改版孕周数", "孕妇BMI", "Y染色体浓度", "身高"]:
data[c] = pd.to_numeric(data[c], errors="coerce")
data["达标标签"] = (data["Y染色体浓度"] >= 0.04).astype(int)
# BMI分组和聚类
data["BMI分组"] = pd.cut(data["孕妇BMI"], bins=[20, 28, 32, 36, 40, 100], labels=["[20,28)",
      "[28,32)", "[32,36)", "[36,40)", "40+"], right=False)
subgroup_results = []
scaler_cluster = StandardScaler()
for bmi_group in data["BMI分组"].dropna().unique():
group = data[data["BMI分组"] == bmi_group].copy()
if len(group) < 5 or len(group["达标标签"].unique()) < 2:
group["子分组"] = f"{bmi_group}-单组"
else:
cluster_feat = group[["年龄", "体重", "身高"]].fillna(group[["年龄", "体重", "身高"]].mean())

```

```

cluster_feat_scaled = scaler_cluster.fit_transform(cluster_feat)
n_clusters = 2 if len(group) >= 10 else 1
kmeans = KMeans(n_clusters=n_clusters, random_state=42)
group["子分组"] = [f"{bmi_group}-子组{i + 1}" for i in kmeans.fit_predict(cluster_feat_scaled)]
subgroup_results.append(group)
data_with_group = pd.concat(subgroup_results, ignore_index=True)
# 建立模型和优化
group_models = {}
scaler_model = StandardScaler()
model_numeric_feat = ["孕妇BMI", "年龄", "体重", "身高", "更改版孕周数"]
for subgroup in data_with_group["子分组"].unique():
    subgroup_data = data_with_group[data_with_group["子分组"] == subgroup].copy()
    if len(subgroup_data["达标标签"].unique()) < 2 or len(subgroup_data) < 5:
        continue
    X_sub = subgroup_data[model_numeric_feat].fillna(subgroup_data[model_numeric_feat].mean())
    y_sub = subgroup_data["达标标签"]
    X_sub_scaled = scaler_model.fit_transform(X_sub)
    lr = LogisticRegression(random_state=42, max_iter=1000)
    lr.fit(X_sub_scaled, y_sub)
    group_models[subgroup] = {
        "model": lr, "scaler": scaler_model,
        "feat_mean": X_sub[["孕妇BMI", "年龄", "体重", "身高"]].mean(),
        "subgroup_data": subgroup_data
    }
# 最佳时点优化
C1, C2 = 1, 10
results = []
for subgroup, info in group_models.items():
    subgroup_data = info["subgroup_data"]
    avg_feat = info["feat_mean"].values
    ga_min = max(subgroup_data["更改版孕周数"].min(), 10)
    ga_max = min(subgroup_data["更改版孕周数"].max(), 25)
    def risk_function(t):
        pred_data = pd.DataFrame([list(avg_feat) + [t]], columns=model_numeric_feat)
        P_t = info["model"].predict_proba(info["scaler"].transform(pred_data))[:, 1][0]
        return C1 * (1 - P_t) + C2 * t
    result = opt.minimize_scalar(risk_function, bounds=(ga_min, ga_max), method="bounded")
    t_opt = round(result.x, 2)
    results.append({
        "子分组": subgroup,
        "最佳NIPT时点(周)": t_opt,
        "最小风险值": round(result.fun, 3),
        "组内孕妇数": subgroup_data["孕妇代码"].nunique()
    })
optimal_df = pd.DataFrame(results)
print("各子组最佳NIPT时点结果:")
print(optimal_df.to_string(index=False))

```

附录 E 问题四相关代码

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.ensemble import RandomForestClassifier
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.metrics import classification_report, roc_auc_score
from imblearn.over_sampling import SMOTE

# 读取数据
df = pd.read_excel('附件_转换后_末次月经补充.xlsx', sheet_name='女胎检测数据')
df['孕妇编号'] = df.index if '孕妇编号' not in df.columns else df['孕妇编号']

# 特征和目标变量
X = df[['年龄', '体重', '孕妇BMI', '原始读段数', '在参考基因组上比对的比例', '重复读段的比例',
        '唯一比对的读段数', 'GC含量', '13号染色体的Z值', '18号染色体的Z值', '21号染色体的Z值',
        'X染色体的Z值', 'X染色体浓度', '13号染色体的GC含量', '18号染色体的GC含量',
        '21号染色体的GC含量', '被过滤掉读段数的比例', '怀孕次数', '生产次数']]
y = df['染色体的非整倍体'].notnull().astype(int)
X['怀孕次数'] = X['怀孕次数'].astype(str)

# 数据预处理
numeric_features = ['年龄', '体重', '孕妇BMI', '原始读段数', '在参考基因组上比对的比例',
                    '重复读段的比例',
                    '唯一比对的读段数', 'GC含量', '13号染色体的Z值', '18号染色体的Z值', '21号染色体的Z值',
                    'X染色体的Z值', 'X染色体浓度', '13号染色体的GC含量', '18号染色体的GC含量',
                    '21号染色体的GC含量', '被过滤掉读段数的比例', '生产次数']
categorical_features = ['怀孕次数']
preprocessor = ColumnTransformer([
    ('num', Pipeline([('imputer', SimpleImputer(strategy='median'))]),
     ('scaler', StandardScaler())]), numeric_features),
    ('cat', Pipeline([('imputer', SimpleImputer(strategy='most_frequent'))],
     ('onehot', OneHotEncoder(handle_unknown='ignore'))]), categorical_features)
])

# 数据分割
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42,
                                                    stratify=y)

# SMOTE过采样
X_train_processed = preprocessor.fit_transform(X_train)
smote = SMOTE(random_state=42)
X_train_resampled, y_train_resampled = smote.fit_resample(X_train_processed, y_train)

# 随机森林模型和网格搜索
```



```

param_grid = {
    'n_estimators': [100, 200, 300],
    'max_depth': [10, 15, None],
    'min_samples_split': [2, 5],
    'min_samples_leaf': [1, 2]
}

rf = RandomForestClassifier(random_state=42, class_weight='balanced')
grid_search = GridSearchCV(rf, param_grid, cv=5, n_jobs=-1, scoring='f1_macro')
grid_search.fit(X_train_resampled, y_train_resampled)

# 预测和评估
best_model = grid_search.best_estimator_
X_test_processed = preprocessor.transform(X_test)
y_pred = best_model.predict(X_test_processed)
y_pred_proba = best_model.predict_proba(X_test_processed)[: , 1]

# 输出结果
print('最佳参数: ', grid_search.best_params_)
print('AUC值: ', roc_auc_score(y_test, y_pred_proba))
print('\n分类报告: ')
print(classification_report(y_test, y_pred))

# 特征重要性
cat_feature_names = list(preprocessor.named_transformers_['cat'].named_steps['
onehot'].get_feature_names_out(categorical_features))
all_feature_names = numeric_features + cat_feature_names
feature_importance = pd.DataFrame({
    '特征名称': all_feature_names,
    '重要性': best_model.feature_importances_
}).sort_values(by='重要性', ascending=False)

print("\n===== 特征重要性 Top 10 =====")
print(feature_importance.head(10))

# 异常预测结果
test_results = pd.DataFrame({
    '孕妇编号': df.loc[X_test.index, '孕妇编号'],
    '预测标签': y_pred,
    '异常概率': y_pred_proba
})

abnormal_predicted = test_results[test_results['预测标签'] == 1].sort_values(by='异常概率',
    ascending=False)

print("\n===== 被预测为异常的孕妇 =====")
print(abnormal_predicted)
test_results.to_excel('胎儿异常预测结果.xlsx', index=False)
print("\n预测结果已保存至 '胎儿异常预测结果.xlsx'")

```

附录 F 支撑材料目录

 问题一-多元非线性回归.py	2025/9/7 17:34	Python File	13 KB
 问题一-spearman分析.py	2025/9/7 17:32	Python File	10 KB
 问题一-distributed.py	2025/9/7 17:31	Python File	10 KB
 问题四.py	2025/9/7 17:40	Python File	10 KB
 问题三.py	2025/9/7 17:37	Python File	13 KB
 问题二-计算最小孕周.py	2025/9/6 15:14	Python File	4 KB
 问题二-BMI分组与NIPT时点.py	2025/9/7 17:37	Python File	9 KB
 数据处理-孕周转换为小数.py	2025/9/7 10:36	Python File	2 KB
 数据处理-末次月经时间补充.py	2025/9/7 10:39	Python File	5 KB
 QUESTION ONE-y_chromosome_correlation_...	2025/9/7 17:32	PNG 文件	1,338 KB
 问题二_1_最佳时点影响.png	2025/9/7 17:37	PNG 文件	110 KB
 问题二_2_平均风险影响.png	2025/9/7 17:37	PNG 文件	103 KB
 问题二_3_时点变化幅度.png	2025/9/7 17:37	PNG 文件	102 KB
 问题二_4_风险变化幅度.png	2025/9/7 17:37	PNG 文件	98 KB
 问题三_检测误差时点稳定性图.png	2025/9/7 17:37	PNG 文件	115 KB
 问题三_最佳NIPT时点图.png	2025/9/7 17:37	PNG 文件	108 KB
 问题四_roc_curve.png	2025/9/7 17:41	PNG 文件	104 KB
 问题四_混淆矩阵热力图.png	2025/9/7 17:41	PNG 文件	110 KB
 问题四_实际vs预测概率对比.png	2025/9/7 17:41	PNG 文件	288 KB
 问题四_特征重要性Top15.png	2025/9/7 17:41	PNG 文件	247 KB
 问题四_异常孕妇概率分布.png	2025/9/7 17:41	PNG 文件	110 KB
 问题一_1_孕周分布直方图.png	2025/9/7 17:34	PNG 文件	69 KB
 问题一_2_BMI分布直方图.png	2025/9/7 17:34	PNG 文件	62 KB
 问题一_3_核心变量相关性热力图.png	2025/9/7 17:34	PNG 文件	129 KB
 问题一_4_孕周对Y浓度的拟合曲线.png	2025/9/7 17:34	PNG 文件	548 KB
 问题一_5_孕周与BMI交互效应热力图.png	2025/9/7 17:34	PNG 文件	167 KB
 data1.xlsx	2025/9/7 16:05	Microsoft Excel 工...	491 KB
 附件 - 副本.xlsx	2025/9/7 8:32	Microsoft Excel 工...	494 KB
 附件.xlsx	2025/9/4 22:52	Microsoft Excel 工...	471 KB
 附件_转换后.xlsx	2025/9/7 17:29	Microsoft Excel 工...	375 KB
 附件_转换后_末次月经补充.xlsx	2025/9/7 17:29	Microsoft Excel 工...	361 KB
 男胎检测数据.xlsx	2025/9/7 16:02	Microsoft Excel 工...	350 KB
 问题二_分组结果_误差分析_0.5percent.xlsx	2025/9/7 17:37	Microsoft Excel 工...	7 KB
 问题四_胎儿异常预测结果.xlsx	2025/9/7 17:41	Microsoft Excel 工...	10 KB
 预测结果_有效数据.xlsx	2025/9/7 17:35	Microsoft Excel 工...	18 KB
 AI工具使用详情.pdf	2025/9/7 18:35	Microsoft Edge PD...	535 KB